

PROYECTO MODELO DE MACHINE LEARNING

PREDICCIÓN DE SUSCRIPCIÓN A UN DÉPOSITO A PLAZO


[\[CLIC AQUÍ PARA VER LA PRESENTACIÓN GRABADA EN VÍDEO\]](#)

Un modelo para decidir a qué clientes llamar primero

Datos: campaña real de marketing bancario · 45.211 clientes

¿Por qué le interesa al banco que la gente contrate?

*Los depósitos le dan al banco **financiación estable y barata** para su negocio de prestar dinero.*



Por eso importa el modelo: captar por teléfono es caro (solo ~12 de cada 100 contratan). Priorizar a quién llamar capta lo mismo con menos llamadas, y hace más eficiente la financiación que sostiene el negocio del banco.

Beneficios adicionales: fidelización del cliente y menor dependencia de financiación cara en los mercados.

La oportunidad: llamar menos y acertar más


El banco ofrece un **depósito a plazo** por teléfono, pero de cada 100 clientes contactados solo **12 contratan**.

Un depósito a plazo es un producto de ahorro: el cliente inmoviliza dinero un tiempo a cambio de intereses.

Cada llamada cuesta tiempo y recursos.


LA PREGUNTA CLAVE

¿A qué clientes deberíamos llamar primero para contratar más, llamando menos?



De cada 100 clientes contactados, ~12 contratan


A qué clientes conviene llamar primero



Los clientes con más probabilidad

- Los que ya contrataron antes → contratan al 65 % (5× la media).
- En los meses de mayor respuesta (mar, sep, oct, dic).
- Jóvenes y mayores, más receptivos que las edades medias.
- Clientes sin hipoteca ni préstamo (más margen de ahorro).

Cuatro perfiles de cliente que el banco puede accionar



23 % → 6 %

Según su perfil, un cliente contrata casi **cuatro veces más** que otro.

El banco puede **concentrar el esfuerzo** en los dos perfiles fuertes y **despriorizar** ~la **mitad** de la cartera, perdiendo muy pocas contrataciones.

Recomendaciones para la próxima campaña

- 1 **Recontactar a quienes ya contrataron** *es el grupo que más convierte (~65 %).*
- 2 **Concentrar en los meses de mayor respuesta** *marzo, septiembre, octubre y diciembre.*
- 3 **Priorizar los 2 segmentos de alta conversión** *y depriorizar los 2 más bajos (~½ de la cartera).*
- 4 **Limitar el nº de llamadas por cliente** *insistir demasiado reduce la conversión.*

Resultado esperado: la misma conversión con bastantes menos llamadas.

EN RESUMEN


Lo que entregamos al banco

- 1 **Un modelo fiable** *que prioriza a quién llamar, con datos previos a la llamada*
- 2 **Perfiles accionables** *4 segmentos de cliente con conversión del 23 % al 6 %*
- 3 **Recomendaciones claras** *para captar más contratando menos llamadas*

A continuación, el equipo técnico detalla cómo se construye el modelo.

● Procesado de datos

Limpieza de datos · feature engineering · codificación · escalado




• Feature engineering

- 1 Eliminamos **duration** porque solo existe *después* de la llamada → provocaría *data leakage*
- 2 Transformamos **pdays** a binaria: **0 = sin contacto previo**, **1 = contacto previo**.
- 3 Recodificamos **poutcome = unknown** a **no_previous_contact**, alineado con **pdays = -1**.
- 4 Imputamos el valor de unknown en **job** (solo 0.6% unknown) con la **moda del train**.
- 5 Convertimos **default**, **housing** y **loan** a **0/1**.
- 6 Mantenemos **education** y **contact** tal cual: unknown es una **categoría válida**, no un missing real.

Resultado esperado: un dataset más limpio, coherente y listo para modelar.





● Pipelines para modelos

Automatización del preprocesamiento para optimizar la preparación de modelos

● Pipelines para modelos

Se crean 3 pipelines distintos según las necesidades de cada tipo de modelo.

1

Pipeline 1: modelos que sí necesitan escalado y transformaciones

- Logistic Regression, KNN, SVM
- Requieren escalado, transformación de numéricas y OneHotEncoder para categóricas.

2

Pipeline 2: modelos que no necesitan escalado, pero sí OneHotEncoder

- Árboles y ensembles: DecisionTree, RandomForest, XGBoost, LightGBM
- Las numéricas se dejan tal cual.

3

Pipeline 3: CatBoost

- No necesita ni escalado ni OneHotEncoder
- Maneja categóricas de forma nativa.

Cada modelo recibe el preprocesamiento óptimo para su funcionamiento.





● Modelado

Baseline · comparativa de modelos · optimización · evaluación en test

Estrategia y prevención de errores



Objetivo

Priorizar antes de llamar.

Identificar y enfocar los esfuerzos en los prospectos con mayor probabilidad de conversión.



Exclusión de *duration*

Garantizar un entorno de **Zero Data Leakage** eliminando variables que solo se conocen durante o después de la llamada.



Tratamiento del Desbalance

Aplicar técnicas de balanceo para ajustar la disparidad de clases objetivo en los datos **(88% vs 12%)**.

El torneo de Baselines y elección del ganador

Modelo	ROC-AUC	F1-Score (Clase 1)	Recall (Clase 1)	Precisión (Clase 1)
★ CatBoost	0.8031	0.4728	0.6285	0.3789
SVM	0.7965	0.4626	0.6229	0.3680
LightGBM	0.8012	0.4587	0.6437	0.3564
XGBoost	0.7739	0.4422	0.5803	0.3572
Regresión Logística	0.7740	0.3827	0.6408	0.2728
Random Forest	0.7883	0.3234	0.2155	0.6477
KNN	0.6932	0.3046	0.2108	0.5493

Resultados finales ordenados por F-1 Score y elección del ganador.

Optimización y rentabilidad en el Call Center

Métrica Clave	CatBoost (Baseline)	CatBoost (Optimizado)
ROC-AUC Score	0.8005	0.8038 ↑
F1-Score (Clase 1)	0.4642	0.4744 ↑
Precisión (Clase 1)	0.3693	0.3856 ↑
Recall (Clase 1)	0.6248	0.6163 ↓

Impacto de negocio tras el ajuste de hiperparámetros (GridSearchCV).

38.56%

Precisión de Venta (Conversión)

Triplizamos la eficiencia del call center respecto al 11.7% de base al llamar a ciegas.




6,946

Llamadas Innecesarias Evitadas

Capturamos casi el 62% del mercado objetivo, ahorrando valioso tiempo operativo.



● FEATURE IMPORTANCE



Caja Negra abierta

Verificando la lógica del modelo & validación del EDA

Modelo listo para producción

Modelo serializado y exportado en formato *.pkl*


Recomendaciones y retorno operativo

- 1** **Recontactar a clientes con éxito previo:** *es el grupo que más convierte (~65 %).*
- 2** **Concentrar en ventanas de alta respuesta (mar, sep, oct, dic):** *El análisis de importancia demuestra que el mes de llamada gobierna el éxito de conversión.*
- 3** **Priorizar los clústeres de alta conversión** *y depriorizar los más bajos (~½ de la cartera).*
- 4** **Triplicar aciertos y limitar la insistencia:** *Pasamos a una Precisión del 38.56% y evitamos 6,946 llamadas inútiles.*

Resultado demostrado: Cerrar el mismo volume de ventas ahorrando casi 7,000 llamadas comerciales innecesarias.

● CONCLUSIONES

Visualización de Impacto por cada 100 contactos




12% Conversión Original

Éxito promedio si contactamos a los prospectos completamente a ciegas (~11.7%).



+27% Incremento IA

Ventas extra logradas por cada 100 llamadas al enfocar el esfuerzo en la población recomendada por CatBoost.



61% Riesgo Mitigado

Llamadas filtradas y evitadas con baja o nula probabilidad de éxito.

El salto del 11.7% de conversion original al 35.8% apalancado por el modelo de IA .